

ปัจจัยเสี่ยงของการ ติด **KT** ในนักศึกษา มหาวิทยาลัยมুমไบ

การสำรวจและวิเคราะห์ข้อมูลเบื้องต้น (Exploratory Data Analysis)
ค่าสถิติเชิงพรรณนา · ความสัมพันธ์ระหว่างตัวแปร

ชุดข้อมูล 10,000 records × 21 features

จำแนกปัจจัยที่ทำให้นักศึกษาสอบไม่ผ่านและต้องสอบแก้ (Keep Terms)



ที่มา บริบท และความสำคัญของชุดข้อมูล

1

ที่มา (Source)

- ชุดข้อมูล Mumbai University KT Students
- นักศึกษาคณะวิศวกรรมศาสตร์ในเครือ University of Mumbai (อินเดีย)
- 1 แถว = นักศึกษา 1 คน · 10,000 แถว × 21 คอลัมน์

2

บริบท: KT คืออะไร

- KT = "Keep Terms" = สอบไม่ผ่าน รายวิชา แต่ยังเลื่อนชั้นได้
- ต้องสอบแก้ (backlog) วิชานั้นภายหลัง
- เทียบได้กับการ "ติด F / ติดค้างวิชา" ในระบบไทย

3

ความสำคัญ (Why)

- อัตราการติด KT = ตัวชี้วัดความเสี่ยง การคงอยู่และการจบการศึกษา
- ตัวแปรครบทั้ง demographic / พฤติกรรม / ระบบสนับสนุน / ผลลัพธ์
- รู้ปัจจัยล่วงหน้า → ออกแบบระบบ early-warning ได้

โครงสร้างชุดข้อมูล — 21 คอลัมน์ • 6 กลุ่ม

10,000 แถว (rows)

21 คอลัมน์ (columns)

74% ติด KT ≥ 1 วิชา

กลุ่ม	คอลัมน์
รหัส (1)	Student_ID
Demographic (4)	Age · Gender · Branch · Year_of_Study
การเดินทาง (2)	Commute_Mode · Commute_Time_mins
พฤติกรรม / เวลา (4)	Attendance_% · Study_Hours · Social_Media_Hours · Sleep_Hours
ระบบสนับสนุน (5)	Part_Time_Job · Extracurricular · Peer_Learning · Mentorship · Financial_Status
ผลลัพธ์ / เป้าหมาย (5)	Previous_Semester_SGPA · Stress_Level · Number_of_KTs · Has_KT · Cleared_in_First_Attempt

คุณภาพข้อมูล

0

แถวซ้ำ / รหัสซ้ำ

ข้อมูลสะอาด ไม่ต้อง de-duplicate

~2%

ค่าหาย ใน 4 คอลัมน์ตัวเลข


Study / Social_Media / Sleep / SGPA ·
กระจายแบบสุ่ม (คล้าย MCAR)

3 → 1

คอลัมน์เป้าหมายที่ซ้ำซ้อน

Has_KT $\equiv$ (KTs>0) $\equiv$ ตรงข้าม Cleared →
ระวัง target leakage

แผนที่ค่าหาย (Missing-Value Map)



อ่านกราฟ

- ช้าย: อัตราค่าหายรายคอลัมน์ อยู่ที่ ~2% เท่านั้น
- ขวา: จุดค่าหายกระจายทั่วตาราง ไม่เกาะกลุ่ม

นัยยะ

- รูปแบบคล้าย MCAR → เติมด้วย median / model-based ได้
- ไม่จำเป็นต้องตัดแถวทิ้ง

สถิติเชิงพรรณนา — ตัวแปรตัวเลขทั้ง 8


feature	mean	std	min	median	max	skew	kurtosis
Age	21.02	2.02	18	21	24	-0.01	-1.28
Commute_Time_mins	69.10	35.11	10	67	180	0.30	-0.54
Attendance_Percentage	69.19	14.64	20	69	100	-0.13	-0.23
Study_Hours_per_Day	2.99	1.47	0	3.0	8.5	0.10	-0.33
Social_Media_Hours_per_Day	3.51	1.49	0	3.5	8.0	0.07	-0.23
Sleep_Hours_per_Night	6.52	1.19	3.0	6.5	10.0	0.02	-0.13
Previous_Semester_SGPA	5.53	0.86	2.32	5.52	9.08	0.02	-0.04
Number_of_KTs	1.54	1.33	0	1	7	0.79	0.44

ทุกตัว $|\text{skew}| < 0.8 \rightarrow$ ค่อนข้างสมมาตร ($\text{mean} \approx \text{median}$) · kurtosis ติดลบเกือบทั้งหมด $\rightarrow$ หางบาง / ค่อนข้างแบน

ตัวแปรจัดกลุ่ม — การกระจายเด่น

ตัวแปร	การกระจาย (%)
Gender	Male 59.0 · Female 39.2 · Other 1.8 (ไม่สมดุล)
Branch	Computer Eng. 25 · IT 20 · AI&DS 15 · EXTC 14 · อื่น ๆ 26
Year_of_Study	First / Second / Third / Final $\approx$ 25% เท่ากัน
Commute_Mode	Local Train 55 · Bus 20 · Two-Wheeler 15 · Walking 5 · Auto/Cab 5
Financial_Status	Middle 55 · Upper Middle 25 · Lower Middle 15 · Wealthy 5
Stress_Level	Low 50 · Medium 32 · High 18
Has_KT	Yes 74.1 · No 25.9 (class imbalance)

การแจกแจงตัวแปรตัวเลขทั้ง 8



รูปทรงการแจกแจง


- เส้นแดง = mean, เส้นเขียว = median
- เกือบทุกตัวสมมาตร $\text{mean} \approx \text{median}$

ข้อสังเกต


- Number_of_KTs เบ้ขวาเล็กน้อย (ข้อมูลนับ)
- Age เป็นแบบไม่ต่อเนื่อง (18–24 ปี)

ตัวแปรเป้าหมาย — Number_of_KTs & Has_KT

Target Variable Distribution



Has_KT (class imbalance 74 : 26)



เป้าหมาย

- ค่าเฉลี่ย 1.54 วิชา/คน · median 1 · สูงสุด 7
- 74% ของนักศึกษาติด KT อย่างน้อย 1 วิชา


นัยยะต่อการสร้างโมเดล

- คลาสไม่สมดุล (74 : 26)
- ควรใช้ metric เช่น F1 / ROC-AUC แทน accuracy

ความสัมพันธ์ระหว่างตัวแปร

- **ตัวเลข × ตัวเลข** Pearson & Spearman correlation · regression
- **ตัวเลข × กลุ่ม** boxplot / violin · ค่าเฉลี่ยและมัธยฐานแยกกลุ่ม
- **กลุ่ม × กลุ่ม** crosstab · stacked bar · Cramér's V (ค่าความสัมพันธ์)

ความสัมพันธ์ ตัวเลข × ตัวเลข




สัมพันธ์กับ Number_of_KTs

- SGPA เดิม $r \approx -0.35$ (แรงสุด)
- Study_Hours -0.30 · Attendance -0.30
- Social_Media $+0.18$ · Commute_Time $+0.11$

โครงสร้างรวม

- Pearson $\approx$ Spearman $\rightarrow$ ความสัมพันธ์เชิงเส้น
- ตัวแปรอินพุตสัมพันธ์กันเองต่ำ $\rightarrow$ ไม่มี multicollinearity


ปัจจัยตัวเลข แยกตามสถานะ Has_KT



รูปทรงการกระจายแยกกลุ่ม

- กลุ่มติด KT: SGPA / เข้าเรียน / ชั่วโมงอ่าน ต่ำกว่าชัดเจน
- กลุ่มติด KT: โซเชียล / เวลาเดินทาง สูงกว่า
- ความต่างของมัธยฐานสองกลุ่มเห็นชัดทุกปัจจัย
- การนอนต่างกันเล็กน้อย

ค่าเฉลี่ยจำนวน KT แยกตามตัวแปรกลุ่ม




ปัจจัยกลุ่มที่แยกได้ชัด

- Stress_Level: เฉลี่ย 0.6 → 1.9 → 3.5 วิชา
- Commute_Mode: Local Train แยกว่า โหมดอื่น
- มี Peer_Learning / Mentorship = KT น้อยกว่า

แถบ error = ช่วงเชื่อมั่น 95%

ความสัมพันธ์ กลุ่ม × กลุ่ม (Cramér's V)




Cramér's V (0–1)

- Stress_Level × Has_KT: สูงเด่นชัด (~0.56)
- Peer_Learning / Mentorship × Has_KT: อ่อน (~0.12)

ข้อสังเกต

- demographic (เพศ สาขา ชั้นปี ฐานะ) เป็นอิสระต่อกัน
- ชุดข้อมูลออกแบบให้ตัวแปรพื้นฐานไม่พันกัน

Stress_Level x Has_KT — ความสัมพันธ์ที่แรงที่สุด



สัดส่วนติด KT ตามระดับ ความเครียด

- Low → 50% · Medium → 98% · High → 100%


- ความสัมพันธ์แรงมาก (Cramér's V = 0.56)

ข้อควรระวัง

- ความเครียดอาจเป็น "ผล" ของการติด KT ด้วย

- → อย่าใช้เป็น predictor แบบไร้เงื่อนไข

Pairplot ปัจจัยตัวเลขหลัก (สี = Has_KT)



ภาพหลายมิติ

- กลุ่มสองสี (ติด / ไม่ติด KT) เหลื่อมกันมาก
- ไม่มีคู่ตัวแปรใดแยกกลุ่มได้ชัด

นัยยะ

- ต้องใช้หลายปัจจัยร่วมกันในการทำนาย
- เหมาะกับโมเดลที่รวมหลาย feature
- (เช่น logistic regression / decision tree)

สรุปข้อค้นพบ (1/2)

โครงสร้าง & คุณภาพข้อมูล

- $10,000 \times 21$ · ไม่มีแถว/ID ซ้ำ · ค่าหาย ~2% เฉพาะ 4 คอลัมน์ตัวเลข กระจายแบบสุ่ม
- Has_KT, Cleared_in_First_Attempt, (Number_of_KTs>0) = ข้อมูลชุดเดียวกัน → ระวัง target leakage

สถิติเชิงพรรณนา

- ตัวแปรตัวเลขแจกแจงสมมาตร ($|\text{skew}| < 0.8$) · kurtosis ตีตก (หางบาง) คล้ายสุ่มจาก uniform/normal
- เป้าหมายไม่สมดุล: 74% ติด KT · เฉลี่ย 1.54 วิชา/คน · สูงสุด 7

สรุปข้อค้นพบ (2/2)

ความสัมพันธ์

- ลด KT: SGPA เดิม ($r \approx -0.35$), ชั่วโมงอ่านหนังสือ (-0.30), การเข้าเรียน (-0.30)
- เพิ่ม KT: ชั่วโมงโซเชียล ($r \approx +0.18$), เวลาเดินทาง ($+0.11$); การนอน/อายุ แทบไม่มีผล
- ปัจจัยกลุ่มที่แยกความเสี่ยงชัด: Stress_Level ($0.6 \rightarrow 3.5$) รองลงมา Commute_Mode, Peer_Learning, Mentorship
- ไม่มีผล: เพศ, สาขา, ชั้นปี, ฐานะการเงิน, กิจกรรมนอกหลักสูตร
- ตัวแปรอินพุตสัมพันธ์กันเองต่ำ $\rightarrow$ ทุกตัวให้ข้อมูลเสริมกัน ไม่มี multicollinearity

นัยเชิงปฏิบัติ

- กลุ่ม "เครียดสูง + เข้าเรียนน้อย + โซเชียลเยอะ + SGPA ต่ำ" คือเป้าหมายของระบบ early-warning



ขอบคุณครับ

ชื่อ-สกุล: ธนเสริฐ ตั้งตรงสกุลดี

รหัสนักศึกษา: 6805007181